#### (0)line群裡的evernote連結

https://www.evernote.com/shard/s379/sh/5b5a1fdb-f5e4-40ee-bd8e-666c3f6ae3de/PDiHx0j2eqGqNBpwTjX7x1dLILlcqtS34A3K1Z1PvdQKRZDvIxy9KmNkTQ

#### (1)google ppt

https://docs.google.com/presentation/d/1spk0yaP0GFeoothcGUzVKUge3KSPXeAvDKnCPbTLzgg/edit?usp=sharing

#### (2)google meet

如要加入這場視訊會議,請按一下這個連結:

# https://meet.google.com/gvf-qahv-ikd

你也可以透過電話加入通話, 只要撥打 +1 385-645-8135, 然後輸入以下 PIN 碼即可:618 812 916#

如要查看其他電話號碼,請按一下這個連結:https://tel.meet/gvf-qahv-ikd?hs=5

#### (3) 簡報正式區

## 我們的報告.ppt

謝弘軒	資科專一	111971022
郭書瑋	資科專一	111971023
周正晏	資科專一	111971003
胡元亨	資科專一	111971024
施宗佑	資科專一	111971005
楊昇豐	資科專一	111971013

目標:下週四5/18, 能夠讓B組的接手做視覺。

google ppt, <u>分享連結</u>出來, 有結果就貼上去。

5/18

5/25 ← 下課討論

6/1 ← 下課討論 (30分鐘以內)

6/8 —>version1

6/12(-) version1

6/14(三) version2

6/15 —> version3

# 6/14

昇豐:readme

1. 刪除此部分

#### **Ouick start**

If our topic interests you, please follow the instructions below to replicate our experimental results.

Rscript code/main.R --data\_source 1 --model 1

此區域改放置指示我們<mark>文件</mark>擺放的git目錄位置。正晏:檔案將 放在docs中。

文件是:3個pdf檔案,來自

「簡報正式區、簡報草稿、此份google doc」下載的pdf檔案。

2. 在此部分, 幫忙加上3個模型的執行語法與預估執行時間 決策樹(預估3~6分鐘)

Rscript code/main.R --d 1 --m 1

隨機森林(預估2~5分鐘) Rscript code/main.R --d 2 --m 2 XGBoost(預估1~2分鐘) Rscript code/main.R --d 2 --m 3

使用不同模型執行預測,產生各模型預測結果

```
Rscript code/main.R --data_source 1 --model 1
```

#### 參數:

- o --data\_source or --d: 選擇使用的資料集(1: 原始資料, 2: 已處理後資料)
- o --model or --m: 選擇使用的模型(1: Decision tree, 2: Random forest, 3. XGBoost)

#### 提醒

- 已處理後資料:表示先經過Data process&smote切割後的資料集
- o Decision tree: 不支援使用已處理後資料,且耗時較長

# 6/12

### 昇豐:

- 一、test set的沒病、有病的比例?我自己試仍然約是10:1
- 二、在google doc 6/8的【2. 簡報已完成,可以放到正式區以 黑體字標示: 】 能看到今日完成的項目,有以下:

- (3) 各模型的執行情況、(4-2) 介紹此方案、(4-3) 再次重申評估與結論
- 、(5) 專案艱辛之處、(6) demo、(7) 專案引用的套件與外部資料、(8) 其他附件。

## 今晚不用急著美化統整, 我在草稿區講可以。

\_\_\_\_\_

三、簡報正式區(Austin整理)第9頁, 我理解此頁要表示綜合 VIF, 你挑選出4個有效性高的欄位。但這並不是我們討論要 在介紹資料集得出的結論

資料集介紹	特徵選擇後
依照統計分析、直覺看來,得 出哪幾個欄位可能跟心臟病 有關。 9個欄位	挑選出13個欄位確實跟心臟 病有關。
在(4-3) 再次重申評估與結論,	比較

四、簡報第51頁的表格幫忙加至正式區。

五、正式區請為我(<u>111971013@g.nccu.edu.tw</u>)開立編輯權限。

[Austin] Done, 6/12.

6/8

### 資料分析圖示

Rscript data plot.R

#### 主程式

Rscript main.R --d 2 --m 1

參數

- --data source or --d
- 1:讀取原資料,會處理dummy和smote
- 2:讀取已處理資料
- --model or --m
- 1:decision tree (不支援data\_source = 2)
- 2:random forest
- 3:xgboost

#### 昇豐:

- p10 沒有表達完全
- 綱要順序:(1)about dataset、(2)資料前處理、(3)各模型的執行情況、(4)介紹最終建議方案、(5)專案艱辛之處、(6)demo、(7)專案引用的套件與外部資料(不會講)、其他附件
  - about dataset的小結(覺得那些欄位是有關的)
  - 1. 簡報尚未完成的部分:
- (1) 專案艱辛之處:各人至少生一則。我的想法是統合1~2頁 放在一起講。

都寫了

(2) 專案引用的套件與外部資料。我的想法是統合放在, 但毋須講。

我、busky、austin; 元亨、書瑋會補

(3) 介紹最終建議方案:

我不確定 元亨/書瑋、正晏/Busky簡報綱要與草稿 是否已經完成;今晚下課後討論看這週日晚上7~9點線上見。

虚擬碼、執行流程圖

- (4) demo, 今晚下課後看看執行效果。
- 2. 簡報已完成,可以放到正式區以黑體字標示: (以下6大點就是正式報告的順序要點)
- (1) 資料集介紹。Austin已放在正式區。
- (2) 資料前處理, 第50~52頁, 示意圖

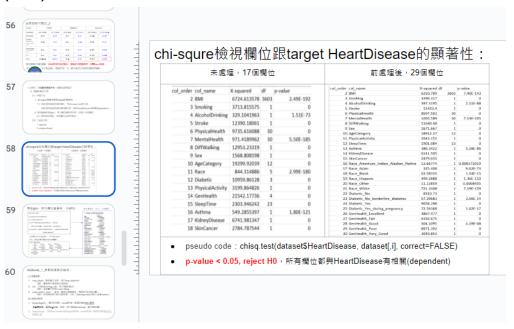


(3) 各模型的執行情況, 第54、55頁, 示意圖\_\_\_20230612完成



# (4) 介紹最終建議方案:

(4-1) 特徵工程, 第58~59頁, 示意圖



## (4-2) 介紹此方案, 第60~68頁, 示意圖\_\_\_20230612完

成

決策樹)

(以random forest、xgboost為主;若篇幅不夠、才加入



## (4-3) 再次重申評估與結論 第69頁, 配合Austin正式區的第6~9頁, 示意圖



# (5) 專案艱辛之處\_\_\_\_20230612完成

第73頁,整合昇豐、書瑋、宗佑、正晏、元亨,示意圖;請

Austin最想要講的內容加在空白處可。



#### 專案艱辛之處

異豐:從「<u>思想的巨人,行動的侏儒」中脫離,進行行動力變革</u>。讀過不少ML、DS、統計的書,但工作既不是此領域、大學的統計 也沒學好,因此這段期末報告的連備過程真的是練習對抗的過程;所幸考試後的課程會提點分析工具選用的缺竅外,老師也願意給 予意見。組員也願意與信任地按照我仿照課堂教科書訂定的報告網要準備。

書達:第一次接觸資料分析,也是第一次接觸R,都是透過上課及作業學到的東西,加上不斷地Google及詢問ChatGPT,慢慢拼凑出景後的結果。

元亨:(程式的互相合作)我們總共採用了3種(決策樹、陸機森林、Xgboost)模型來分析資料,實際寫了5份建模程式及1份視覺化程式 ,在這些Code中,每個人的Code pattern,前處理,套件運用等都不盡相同,讓我們在海通、整合程式時費了一番功夫。

正要:(對於不熟悉領域的探索)平時在於工作中並未使用到與Data Science相關的技能,本次專案算是一個新領域的探索,在專案建立的過程中,除了需要時不時複習老師上課的內容之外,還需要不斷地去學習,在資料集確定後就遇到了第一個難關,在不同的模型上,會針對其所需要的輸入去調整Attribute,在建模的過程中,發現若不了解模型的原理,在參數的值上也難以去調整。

宗佑:(資料集不平衡)本主題資料集相當不平均,患者與非患者為1比13,基本上使用null model全部猜測患者無病,準確性即高達九成多。然而這樣的猜測沒有太大意義,因此我們針對不平衡的資料瀏覽許多資料,最後透過smote,降低樣本比例至1比4,提高sensitivity。

#### 以上來自

昇豐:第71頁的第1點

元亨:第11頁的第2點

書瑋:第10頁的第1點

正晏:第24頁的第2點

宗佑:第47頁的第1點

(6) demo, 第70頁\_\_\_20230612完成



# (7) 專案引用的套件與外部資料(不會講)

昇豐:第72頁的第2點,示意圖



元亨:第11頁的引用資料 書瑋:第10頁的引用資料

正晏:暫無宗佑:暫無

## (8) 其他附件(不會講)

1. 將大家所有的專案艱辛之處放此:

昇豐:第71頁

元亨:第11頁

書瑋:第10頁

正晏:第24頁

宗佑:第47頁

2.

# 6/5

## 昇豐:

- 1. 6/12 21:30 線上簡報試講
- 2. 簡報尚缺, 請各自補齊

建議的最終方案

- (4) 專案艱辛之處(各自都要寫)
- (5) 專案引用的套件與外部資料

[Ausitn]

library(dplyr) -> bar chart plot

library(ggplot2) -> box chart plot

# 元亨:

Roc, importance用圖

其餘用數值(csv)

Accuracy:0.82 Precision:0.27

sensitivity(Recall):0.66

Specificity:0.83

F1 Score:0.38

Setting levels: control = 0, case = 1
Setting direction: controls < cases

AUC:0.74

#### Austin:

1. 請大家去readme分支看,還需要增減再說;也能告知簡報哪 頁可以'直接用。

昇豐:我認為分兩部分,第一部分說明如何執行專案,產生什麼用途的檔案。第二部分按照6/8的「6大點就是正式報告的順序要點」,依序貼圖就好。

# 6/1

### 昇豐:

0. 我們沒有計算model的R-square(correlation^2)、RMSE。

## 決策樹沒法計算R-square

<u>https://stats.stackexchange.com/questions/171762/explanatory-power-of-a-de</u> cision-tree

https://stackoverflow.com/questions/40901445/function-to-calculate-r2-r-squared-in-r

1. 能確定A組夥伴會提供那些簡報(請補充階層式綱要):

資料集介紹會有小結論, 分析也會有小結論, 最後一起 參照。

週一根據欄位重要性的集合, Austin就可以更改資料集介紹的投影片。

- (1)前處理:昇豐
- (2)建模

特徵工程

A-2. PCA: 昇豐(prcomp)

A-3. cols correlation:昇豐、書瑋 沒有辦法效率挑出欄位,因此不放col

correlation.

A-4. chi-squre看看特徵跟output的顯著性 昇豐

A-1. 欄位重要性:昇豐(glm)、書瑋(random)、正晏 +busky(xgboost)

建立

B-1. f-fold 昇豐

B-2. train/test 元亨、書瑋、正晏、busky

B-3. null model busky

## (3) 評估

C-1. confusion matrix相關的計算(precision、recall、specificity、F1、sensitivity)

C-2. 得出結論

- (4) 專案艱辛之處(各自都要寫)
- (5) 專案引用的套件與外部資料

# (6) demo的簡報(請補充階層式綱要) 生豐

- 2.6/5 專題研討下課後討論
  - 1. 確認<u>簡報草稿</u>哪一部分可以給Austin處理。
- 2. 討論Readme要寫啥?我建議就照此份google doc最末的要點按順序撰寫。<mark>需要切專屬的分支</mark> Austin、正晏

2.1. goal : 要解決什麼問題?我們就可定義期末報告的主題集合。

2.2. data(input):

a. 資料前處理:有無發現資料清洗的難處?

2.3. model :

- a. 選哪個模型進行ML? 例如決策數、XGBoost。
- b. 選用哪個特徵工程來優化模型?
- c. null model定義與建立。
- 2.4. evaluation(ouput):

5/29

### 書瑋:

程式執行指令: Rscript main.R fold 跑 mtry = 26, 確認是否overfitting

# important 特徵數值

- MeanDecreaseAccuracy: Accuracy的差異, 越大表示該參數 越重要
- MeanDecreaseGini: Gini的差異, 越大表示原參數資料較純, 表示參數越重要

	MeanDecreaseAccuracy	MeanDecreaseGini
AgeCategory	66.4559862	5102.20891
Sex	37.6880821	881.84802
ВМІ	37.1622488	10321.42351
PhysicalHealth	30.9170674	2258.00245
GenHealth_Good	30.1246583	404.42644
MentalHealth	29.1394247	2048.08265
Stroke	28.415993	1133.09927
Smoking	22.5007621	847.41524
SleepTime	20.7433561	3126.5215
DiffWalking	19.5596559	1277.51228
Diabetic_Yes	18.6405389	460.41111
SkinCancer	16.6379981	726.61206
Diabetic_No	15.5995019	347.23006
KidneyDisease	15.4077994	483.8291
Race_White	13.744645	447.52379
GenHealth_Fair	13.5128123	476.07484
Asthma	13.0573223	707.78092
PhysicalActivity	12.1913921	896.01873
GenHealth_Poor	11.0608412	519.43874
AlcoholDrinking	8.7604312	381.97716
Race_American_Indian_Alaskan_Native	7.9394651	132.96757
GenHealth_Excellent	7.2776512	301.70271
GenHealth_Very_Good	5.6273062	384.66317
Race_Hispanic	5.3366421	296.68296
Race_Black	4.8108654	297.79088
Race_Asian	3.3330838	100.19364
Race_Other	3.0147184	189.18748
Diabetic_No_borderline_diabetes	2.8732792	185.05434
Diabetic Yes during pregnancy	-0.7281113	39.80911

AgeCategory+Sex+BMI+PhysicalHealth+GenHealth\_Good+MentalHealth+Stroke+Smoking+SleepTime+DiffWalking+SkinCancer+KidneyDisease

# 昇豐:

1. smote為何會產生NA?

- 參數k的分群

https://rdrr.io/cran/performanceEstimation/man/smote.html

https://stackoverflow.com/questions/62871492/create -balanced-dataset-11-using-smote-without-modifyingthe-observations-of-th

https://stackoverflow.com/questions/73574827/smote -r-outputting-rows-of-nas

- 我選用smote\_performanceEstimation 的根據 https://stackoverflow.com/questions/67085791/packa ge-to-do-smote-in-r
- 2. 等待random forest、xgboost的欄位重要性數值,看看跟邏輯回歸跑出來的差多少?
- 2.1. 這週四問家銘不同模型跑出的欄位重要性, 孰優孰劣? ←— teacher說, 把欄位組合拿去跑model最準。沒有標準答案。

能否用A模型產出的欄位重要性,運用到B模型<----teacher說可以

3. 書瑋提供的繪圖:

## https://r-graph-gallery.com/index.html

4. 確認元亨的訓練集smote後, 比例是否真為1:1.33。(應該要是1:4。) 餵入訓練集的資料量造成差異。21萬筆的確如此

## 元亨:

- 1. 程式執行指令: Rscript Jude\_111971024.R --input ../data/heart\_2020\_cleaned.csv
- 2. pre-processing模組化是否和書瑋重工 宗佑:

# 1.程式執行請看Readme第一行,下面的使用現成smote後資料, 速度較快。

Rscript code/xgboost\_111971005.R --input data/heart\_2020\_cleaned.csv run smote with raw data "heart 2020 cleaned.csv"

Rscript code/xgboost\_111971005.R --input data/heart\_2020\_smote.csv use already smote data "heart 2020 smote.csv"

# 5/25

#### 今晚討論

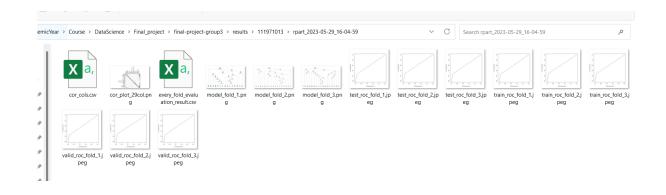
#### 昇豐:

- 1. 5/29 晚上9:30線上討論, 可以?
- 1. 看各模型tune的結果(precision recall f1 auc roc)、圖片。
  - 2. 看看欄位共線性、解釋density graph的優化成果。 還沒研究:解釋density graph
  - 3. 各自程式推到gitrepo;試試看Rscript.exe能不能過。
    - 3.1. 昇豐的branch: 111971013\_Carter
    - (1)cd to path : \final-project-group3\code Windows執行方式
    - (2-1) & 'C:\Program Files\R\R-4.3.0\bin\Rscript.exe'
  - Carter\_111971013.R --input ../data/heart\_2020\_cleaned.csv
  - --output ../results/111971013 --model\_name rpart

Mac、Linux執行方式

- (2-2) Rscript Carter\_111971013.R --input
- ../data/heart\_2020\_cleaned.csv --output ../results/111971013 --model name rpart
- (3) results/111971013 產生「model name 時間戳記」

#### 的目錄



- 2. GitRepo目錄結構、分支名稱。
  - 1. 目錄:

code/EnglishName\_studentId.R results/ 111971013/csv、json、xlsn、圖片 data/原始資料 docs/ 會議討論【最後上傳】

- 2. 請用 學號+英文姓名開分支, 例如111971013\_Carter
- 3. 簡報
  - 2.1. 原始資料的視覺
  - 2.2. 昇豐處理
  - 2.3. 各自用模型的處理
  - 2.4. 各自用模型的處理
  - 2.5. 各自用模型的產圖出來, 匯集起來看夠不夠
- 4. 請大家用我的smote(套件performanceEstimation)。此份google doc有範例程式, Ctrl +f可找到。
  - 5. 我會再作欄位共線性、解釋density graph。
    - 5.1. 透過qlm()邏輯回歸能計算共線性或者欄位重要性:

sample code
set.seed(55)
f\_in\_nums <- nrow(f\_in\_csv)</pre>

```
fold_interval <- round( f_in_nums / k_fold_num) f_in_csv <- f_in_csv[sample(1:f_in_nums), ] 

smote_f_in_csv <- smote(HeartDisease ~ ., data 
=f_in_csv[c(-(100573:201144), -(201145:301716)),]) 
smote_f_in_csv <- 
smote_f_in_csv[lis.na(smote_f_in_csv$HeartDisease),] 
smote_f_in_csv$HeartDisease<- 
ifelse(smote_f_in_csv$HeartDisease=='Yes',1,0) 

table(smote_f_in_csv$HeartDisease) 
base_cols <- paste(colnames(f_in_csv)[-1], collapse="+") 
model <- glm(paste("HeartDisease", base_cols, sep="~"), 
family="binomial", data=smote_f_in_csv)
```

#### A. 計算共線性:

# > car::vif(model)

Error in vif.default(model) : there are aliased coefficients in the model

若用29欄位進行邏輯回歸,會因為multicollinearity的關係而錯誤;換句話說就是有的欄位彼此間相關性過高!

google search: R car::vif(model) Error in vif.default(model) : there are aliased coefficients in the model

https://www.statology.org/r-aliased-coefficients-in-the-model/

\_\_\_\_\_

----

採取13個欄位, 就可以得到VIF。這些值都很小! 13個欄位並沒有共線性

> car::vif(model)

BMI	Smoking	Stroke
DiffWalking		
1.108250	1.031146	1.021945
1.297409		
Sex	AgeCategory	Asthma
KidneyDisease		
1.059703	1.104021	1.053452
1.036308		
Race_Hispani	c GenHealth_Excelle	ent
GenHealth_Fair	GenHealth_Good	
1.024754	1.229081	1.623939
1.585377		
GenHealth_Po	or	
1.406402		

# B. 欄位重要性():

# > caret::varImp(model)

	Overall
BMI	4.4294187
Smoking	13.0590904
AlcoholDrinking	1.9100625
Stroke	23.3059047
PhysicalHealth	1.5127184
MentalHealth	2.1510181
DiffWalking	6.5815495
Sex	25.4474306
AgeCategory	47.6255661
PhysicalActivity	1.3458511
SleepTime	2.1629561
Asthma	7.2590399
KidneyDisease	9.7363807
SkinCancer	1.7886560
Race_American_	Indian_Alaskan_Native 0.4889626
Race_Asian	3.5278293
Race_Black	3.8891932
Race_Hispanic	4.0550250

Diabetic\_No\_borderline\_diabetes 1.0085721

Diabetic\_Yes 1.2487449

 GenHealth\_Excellent
 7.0720475

 GenHealth\_Fair
 21.7952554

 GenHealth\_Good
 14.6508521

 GenHealth\_Poor
 20.6333198

#### > >4=有13個欄位

base\_cols <-

"BMI+Smoking+Stroke+DiffWalking+Sex+AgeCategory+Asthma+KidneyDise ase+Race\_Hispanic+GenHealth\_Excellent+GenHealth\_Fair+GenHealth\_Good+GenHealth\_Poor"

https://www.statology.org/logistic-regression-in-r/

## 欄位重要性(RandomForest):

0 1 MeanDecreaseAccuracy

BMI 12.963202 29.949534

37.004319

Smoking 10.607566 17.773425

18.861257

AlcoholDrinking 5.811193 20.960525

20.037187

Stroke 18.836935 17.685078

20.910553

PhysicalHealth 10.843591 18.358841

18.118608

MentalHealth 7.589369 12.348783

15.724788

DiffWalking 9.000426 14.566796

15.664644

Sex 11.618129 23.187484

20.606749

AgeCategory 14.414068 31.190656

23.834968

Physical Activity 7.437506 11.081956

10.504036

SleepTime 10.567065 18.226266

14.619381

Asthma 5.924029 16.011459

13.044312

KidneyDisease 10.382129 16.648331

13.511642

SkinCancer 5.782972 9.182070

9.055548

Race\_American\_Indian\_Alaskan\_Native 2.796220 8.695581

8.008274

Race Asian 2.257975 9.966916

10.673360

Race Black 5.107070 12.991173

16.684118

Race Hispanic 1.053984 7.433698

9.833050

Race Other 3.996109 13.471029

15.059658

Race White 2.085537 14.525425

14.785692

Diabetic\_No 5.642429 8.530390

9.900404

Diabetic\_No\_borderline\_diabetes 9.002068 6.038766

11.811424

Diabetic\_Yes 5.471792 15.280870

11.537246

Diabetic\_Yes\_during\_pregnancy 3.494072 6.042743

7.076193

GenHealth Excellent 6.896207 7.159250

8.749628

GenHealth Fair 6.092068 9.868491

10.277100

GenHealth Good 5.306516 4.668623

8.729043

GenHealth Poor 5.548391 12.826259

11.103652

GenHealth\_Very\_Good 7.032531 4.814157

9.173067

MeanDecreaseGini

BMI 1846.32562

Smoking 784.15760

AlcoholDrinking 251.22305

Stroke 1721.21914

PhysicalHealth 2598.42676

MentalHealth 1299.69673

DiffWalking 1905.30743

Sex 1198.62882

AgeCategory 9029.17869

PhysicalActivity 548.96284

SleepTime 2534.90342

Asthma 355.36682

KidneyDisease 528.96042

SkinCancer 522.39528

Race\_American\_Indian\_Alaskan\_Native 96.04153

Race\_Asian 81.16871

Race\_Black 178.81046

Race Hispanic 195.88362

Race\_Other 124.15698

Race\_White 339.69815

Diabetic No 830.56240

Diabetic\_No\_borderline\_diabetes 100.95766

Diabetic Yes 1794.79180

Diabetic\_Yes\_during\_pregnancy 49.00148

GenHealth\_Excellent 1090.18637

GenHealth Fair 1007.33542

GenHealth\_Good 558.47994

GenHealth\_Poor 938.38240

GenHealth\_Very\_Good 864.57548

Roc, importance用圖

其餘用數值(csv)

Accuracy:0.82

Precision:0.27

sensitivity(Recall):0.66

Specificity:0.83

F1 Score:0.38

Setting levels: control = 0, case = 1

Setting direction: controls < cases

AUC:0.74

5.2 PCA的decision tree圖, 我用PC1~PC18; 根據此作法去看看評估效果

xgboost正晏、busky;random forest元亨、書暐、busky;決策 樹昇豐

### 正晏:

- 1. 昇豐建議:資料前處理方法用一致,最後產出30個欄位的資料。
- 2. 書暐: pred=0.5~0.8 (0.1), 用xgboost做看看效果, 下周再來問。

Austin:期末報告老師範例。 信用卡高風險交易預測.pdf 信用卡流失客戶預測.ppt

我們的報告.ppt

5/18

## 今晚討論

1. github 期末專案組別名稱: group3

#### 06月12日 - 06月18日

- finalProject
  - Github final projrct (Click to join your group)

請透過連結加入各組 team,團隊名稱按造分組名單上的組別 group1, group2, .... ,小組中第一個人需要先創立自己的 team,其他人則可以加入已有的 team。

2.

- 1. 正晏:會嘗試xgboost(下週四上課給);視覺化先做dataset。
- 2. 元亨:會嘗試隨機森林(這週四上課給)。
- 3. 昇豐:我會做特徵工程(PCA、ROC、AUC)、Hypothesis Test(chi-squre 完成的話, pass 給宗佑。)

### 進行中PCA:

- >>>需要使用「log1p」取log, 避免0成為infinite。
- >>>Teacher: AUC、ROC會比準確率重要;看看balanced 後的train model的 sensitivity、specificity表現怎麼樣。
- (1) 使用prcomp:

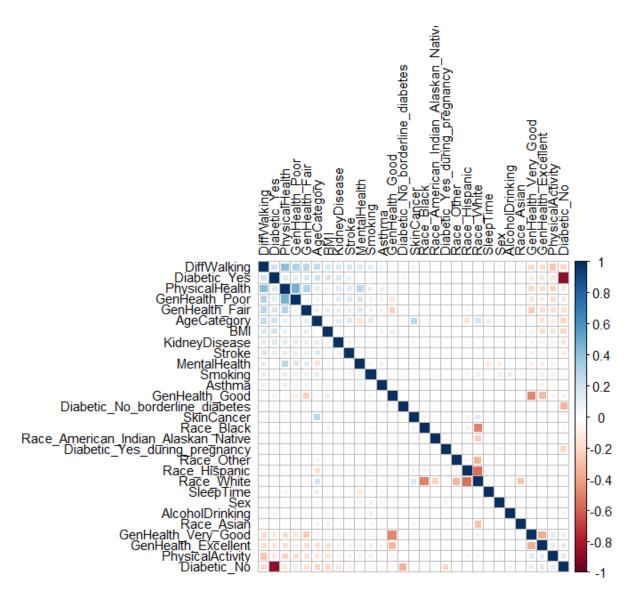
觀察到PC18時,可以解釋0.80525的資料;換句話說,取18個欄位可以

#### (2) 使用FactoMineR method

同樣得到Dim.18(=PC18)能解釋0.80525的資料。

```
log.ir <- log1p(f_in_csv[ ,2:30])
ir.species <- f_in_csv[ ,1]
ir.pca <- PCA(log.ir, graph = FALSE)</pre>
   get_eig(ir.pca)
            eigenvalue variance.percent cumulative.variance.percent
Dim.1
         3.124429e+00
                                1.077389e+01
                                                                           10.77389
Dim.2
Dim.3
                                7.038972e+00
         2.041302e+00
                                                                           17.81286
                                                                           23.84292
28.83429
33.53070
37.92073
          1.748716e+00
                                6.030056e+00
          1.447496e+00
                                4.991366e+00
Dim.4
Dim.5
          1.361959e+00
                                4.696411e+00
          1.273111e+00
                                4.390038e+00
Dim.6
Dim.7
          1.172884e+00
                                4.044426e+00
                                                                           41.96516
Dim.8
          1.137454e+00
                                3.922255e+00
                                                                           45.88742
                                3.782215e+00
Dim.9
          1.096842e+00
                                                                           49.66963
Dim.10 1.084690e+00
                                3.740309e+00
                                                                           53.40994
                                3.606921e+00
3.573473e+00
                                                                           57.01686
Dim.11 1.046007e+00
                                                                           60.59033
64.11407
67.60080
Dim.12 1.036307e+00
                                3.523737e+00
Dim.13 1.021884e+00
Dim.14 1.011152e+00
                                3.486731e+00
                                3.334255e+00
Dim.15 9.669340e-01
                                                                           70.93506
Dim.16 9.475727e-01
                                3.267492e+00
                                                                           74.20255
                                                                           77.38028
Dim.17 9.215427e-01
                                3.177733e+00
                                                                           80.52522
83.61474
Dim.18 9.120333e-01
                                3.144942e+00
Dim.19 8.959607e-01
                                3.089519e+00
                                2.988535e+00
2.892921e+00
Dim.20 8.666751e-01
Dim.21 8.389470e-01
                                                                           86.60328
                                                                           89.49620
         7.558719e-01
                                2.606455e+00
Dim.22
                                                                           92.10265
Dim.23
         7.366622e-01
                                2.540215e+00
                                                                           94.64287
Dim.23 7.366622e-01
Dim.24 5.783772e-01
Dim.25 5.219414e-01
Dim.26 4.532496e-01
Dim.27 4.171453e-23
Dim.28 5.300077e-28
                                1.994404e+00
                                                                           96.63727
                                1.799798e+00
1.562930e+00
                                                                           98.43707
                                                                          100.00000
                                1.438432e-22
                                                                          100.00000
                                1.827613e-27
                                                                          100.00000
Dim.29 3.586657e-28
                                1.236778e-27
                                                                          100.00000
```

(3)cor



### 取19個cor互相為正相關的欄位:

> cor\_cols

[1] "BMI" "Smoking"

[3] "Stroke" "PhysicalHealth" [5] "MentalHealth" "DiffWalking"

[7] "Sex" "Asthma"

[9] "KidneyDisease" "Race American Indian Alaskan Native"

[11] "Race Black" "Race Hispanic"

[13] "Race\_Other" "Diabetic\_No\_borderline\_diabetes"

[15] "Diabetic Yes" "Diabetic Yes during pregnancy"

[17] "GenHealth\_Fair" "GenHealth\_Good"

[19] "GenHealth Poor"

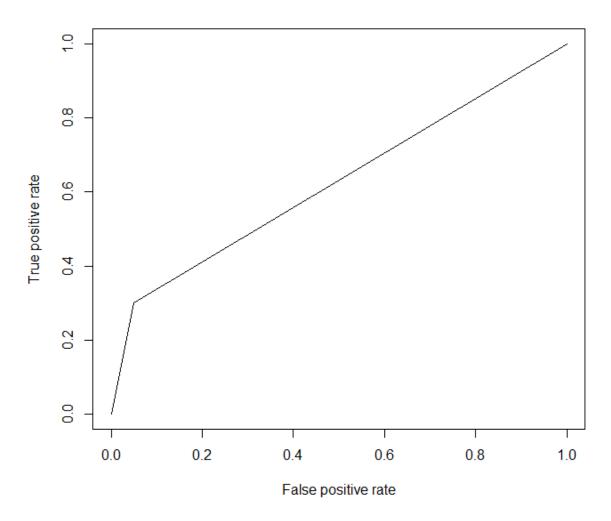
#### 程式碼:

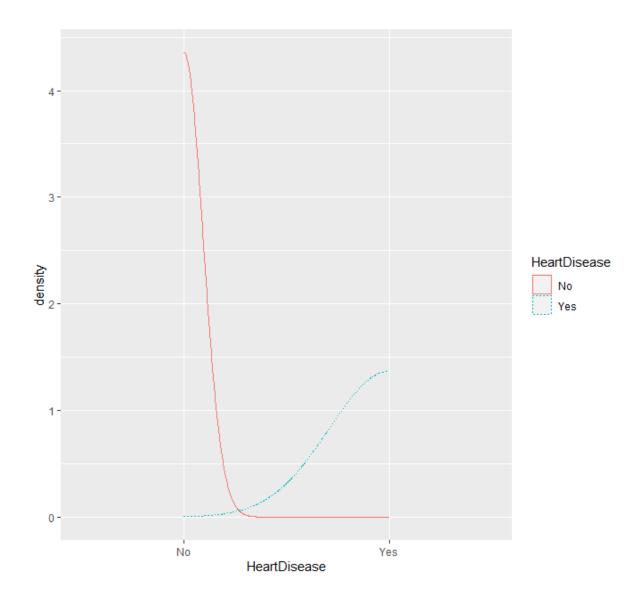
```
#df_cor_f_in_csv <- data.frame(cor(f_in_csv[, -1]))
#cor_cols <- colnames(df_cor_f_in_csv)[df_cor_f_in_csv[1]>0]
```

都是正相關的反而不能全取, 因為有共線性的問題。

(4)AUC ROC

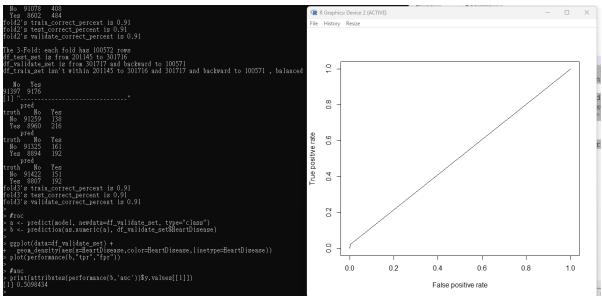
(4-1)用29個欄位; model用smote去train; **AUC=0.6257551**------------較好

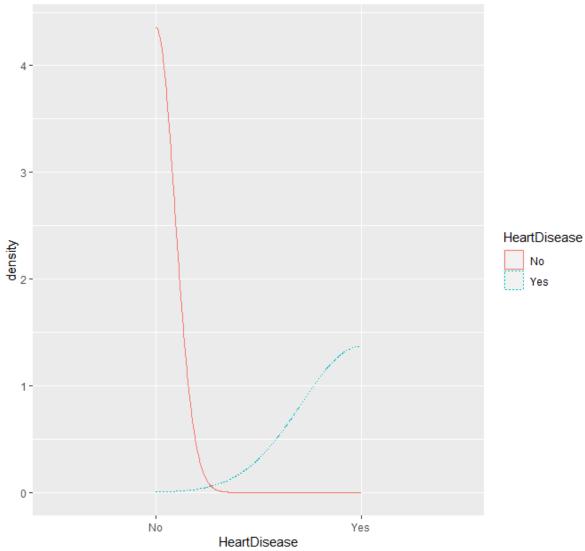




```
>
> print(attributes(performance(b,'auc'))$y.values[[1]])
[1] 0.6257551
>
```

(4-2)用29個欄位; model沒用smote去train; AUC=0.5098434





(5)sensitivity(=recall=True positive rate), specificity(=True negative rate) - 由以下得知, train\_set 一定要處理unbalanced, 模型的AUC才能提高、sensitivity and specificity才會正常一點。
- 選用欄位重要性13個欄位,或者選用PC1~PC18,得出的結果跟

29個欄位差不多。

\*選用PC1~PC22的效果沒有PC1~PC18好。

\*觀察到PC18時, 可以解釋0.80525的資料。

#### 切3個fold,每個fold約10萬。train\_set有取smote、也取29個欄位且排除 NA後,建立決策樹模型

	set	train_Accur acy	test_Accur acy	valid_Accur acy	train_Preci sion	test_Preci sion	valid_Preci sion	train_Sensiti vity	test_Sensiti vity	valid_Sensiti vity	train_Specifi city	test_Specifi city	valid_Specifi city	train_ F1	test_ F1	valid_ F1		_	valid_a uc
1	fold 1	0.82	0.9	0.9	0.63	0.4	0.4	0.25	0.25	0.24	0.96	0.96	0.96	0.36	0.31	0.3	0.6072 1		0.6033 6
2	fold 2	0.82	0.89	0.89	0.61	0.37	0.37	0.29	0.29	0.29	0.95	0.95	0.95	0.4	0.33	0.32	0.6236 7		0.6199 4
3	fold 3	0.82	0.9	0.9	0.64	0.39	0.38	0.27	0.27	0.25	0.96	0.96	0.96	0.38	0.32	0.31	0.6175 1	0.613	0.6070 8
4	bes	fold1	fold1	fold1	fold3	fold1	fold1	fold2	fold2	fold2	fold1	fold1	fold1	fold2	fold2	fold2	fold2	fold2	fold2

切3個fold, 每個fold約10萬。train\_set有取smote、也取PC1~PC18 且排除NA後, 建立決策樹模型

set	train_Accur	test_Accur	valid_Accur	train_Preci	test_Preci	valid_Preci	train_Sensiti	test_Sensiti	valid_Sensiti	train_Specifi	test_Specifi	valid_Specifi	train_	test_	valid_	train_a	test_a	valid_a
	acy	acy	acy	sion	sion	sion	vity	vity	vity	city	city	city	F1	F1	F1	uc	uc	uc

1	fold 1	0.82	0.9	0.9	0.64	0.39	0.4	0.25	0.23	0.24	0.97	0.96	0.96	0.36	0.29	0.3	0.6060 6		0.6014 6
2	fold 2	0.82	0.89	0.9	0.63	0.38	0.38	0.26	0.25	0.25	0.96	0.96	0.96	0.37	0.3	0.3	0.6100 6		0.6028 2
3	fold 3	0.83	0.89	0.89	0.65	0.37	0.37	0.29	0.27	0.27	0.96	0.95	0.95	0.4	0.31	0.31	0.6247 3		0.6124 9
4	bes	fold3	fold1	fold1	fold3	fold1	fold1	fold3	fold3	fold3	fold1	fold1	fold1	fold3	fold3	fold3	fold3	fold3	fold3

切3個fold, 每個fold約10萬。train\_set有取smote、也取PC1~PC22 且排除NA後,建立決策樹模型\_效果更差

	set	train_Accur acy	test_Accur acy	valid_Accur acy	train_Preci sion	test_Preci sion	valid_Preci sion	train_Sensiti vity	test_Sensiti vity	valid_Sensiti vity	train_Specifi city	test_Specifi city	valid_Specifi city	train_ F1	test_ F1	valid_ F1	train_a uc	_	valid_a uc
1	fold 1	0.82	0.9	0.89	0.63	0.38	0.38	0.28	0.27	0.26	0.96	0.96	0.96	0.39	0.31	0.31	0.6184 3	0.613 42	0.61
2	fold 2	0.82	0.89	0.89	0.63	0.38	0.37	0.27	0.26	0.25	0.96	0.96	0.96	0.37	0.3	0.3	0.6130 4		0.6048 5
3	fold 3	0.82	0.9	0.9	0.66	0.39	0.38	0.25	0.24	0.24	0.97	0.96	0.96	0.37	0.3	0.3	0.6108 9		0.6033 5
4	bes	fold1	fold1	fold3	fold3	fold3	fold1	fold1	fold1	fold1	fold3	fold1	fold1	fold1	fold1	fold1	fold1	fold1	fold1

切3個fold,每個fold約10萬。train\_set有取smote、也取13個欄位(根據caret::varlmp)且排除NA後,建立決策樹模型

set train\_Accur test\_Accur valid\_Accur train\_Preci test\_Preci valid\_Preci train\_Sensiti test\_Sensiti valid\_Sensiti train\_Specifi test\_Specifi valid\_Specifi train\_ test\_ valid\_ train\_a test\_a valid\_a

		acy	acy	acy	sion	sion	sion	vity	vity	vity	city	city	city	F1	F1	F1	uc	uc	uc
1	fold 1	0.82	0.89	0.89	0.61	0.37	0.37	0.27	0.27	0.27	0.96	0.95	0.95	0.38	0.32	0.31	0.6147 5	0.614 18	0.6134 5
2	fold 2	0.82	0.9	0.9	0.62	0.39	0.38	0.26	0.26	0.25	0.96	0.96	0.96	0.36	0.31	0.3	0.6090 7		0.6062 9
3	fold 3	0.82	0.89	0.89	0.61	0.37	0.37	0.28	0.28	0.27	0.96	0.95	0.95	0.39	0.32	0.31	0.6199 2	0.616 14	0.6133 7
4	bes t	fold1	fold2	fold2	fold2	fold2	fold2	fold3	fold3	fold1	fold1	fold2	fold2	fold3	fold1	fold1	fold3	fold3	fold1

切3個fold, 每個fold約10萬。 $train\_set$  沒 取smote、也取29個欄位, 建立 決策樹模型

	set	train_Acc uracy	test_Acc uracy	valid_Acc uracy	train_Pre cision	test_Pre cision	valid_Pre cision	train_Sens itivity	test_Sens itivity	valid_Sens itivity	train_Spec ificity	test_Spec ificity	valid_Spec ificity	train_ auc	test_ auc	valid_ auc
1	fol d1	0.91	0.91	0.91	0.62	0.56	0.55	0.03	0.03	0.03	1	1	1	0.513 55		0.513 44
2	fol d2	0.91	0.91	0.91	0.61	NaN	NaN	0	0	0	1	1	1	0.5	0.5	0.5
3	fol d3	0.91	0.91	0.91	0.62	0.59	0.54	0.03	0.03	0.03	1	1	1	0.514 18		0.511 93

(5)chi-squre:檢驗各欄位對output有無顯著

根據鄉民的成果顯示,所有欄位(17個)對於HeartDisease都是顯著的。

4. 書瑋:特徵工程(PCA)【cor 計算欄位相關、ROC、AUC】。

Random Forest importance method

將參數的值隨機化, 觀察變化

- MeanDecreaseAccuracy: Accuracy的差異, 越大表示該參數 越重要
- MeanDecreaseGini: Gini的差異, 越大表示原參數資料較純, 表示參數越重要

測試正晏建議copy YES的資料, 讓它跟NO的依樣多 => 使用ROSE的 over-sampling

d <- ovun.sample(HeartDisease  $\sim$  ., data = d, method = "over",N = 292422\*2)\$data

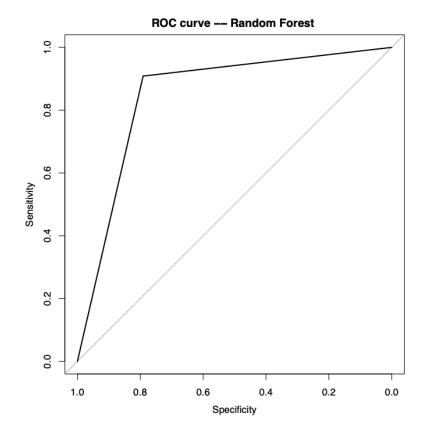


使用Random Forest 產生的 important 如表

https://docs.google.com/spreadsheets/d/1IM2-4hOuF yP3FJt-YIv7QdDRmdFKmODZmsDmDpPo974/edit#gid=2 056993645

Accuracy = 0.85

Area under the curve: 0.8498



5. 宗佑: HW2(null model、以及其他的confusion matrix的計算結果precision recall)

分享我的程式碼

- (1)用list存要測試的model, 然後用for迴圈直接把要測的一起 測試(使用train這個function, 前面list要放method這個參數有支援 的model)。
  - (2)撰寫兩個function去處理confusion matrix, 甲.使用現有套件-confusionMatrix (取名 get\_model\_result)

但是和我使用作業2的方式算出來的sen, spe有落差, 該套件好像是取一個平均值

乙.使用作業2人工計算(取名hw2\_evaluate)

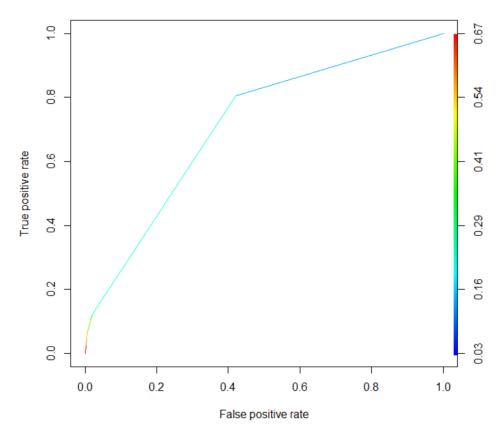
目前完成tp, tn, fp, fn,f1,null-model,sensity, specificity,ROC(TPR, FPR), ROC(Sensity, Specificity),

- [1] "sensitivity is 0.049523110785033"
  [1] "specificity is 0.99555490781899"
  [1] "precision is 0.525291828793774"
  [1] "F1 is 0.0905129064699966"
- (3)尚待完成 計算loglikelihood,

(4)bug

無法一次跑完script,一次跑兩張圖片時候,圖片儲存有問題

備註:目前尚未篩濾任何特徵, 採全部一起挑選進行訓練, 只有使用昇豐的方法針對一些類別的資料進行處理(年紀, 篩濾重複, Yes/No,Male/Femal等轉換為0/1), 目前切成train test valid但是valid還沒用到



這周六晚上12點回報

# 元亨:

## 資料前處理:

- 1. 將資料轉為Numeric
- 2. Train和Valid比率切7:3
- 3. 使用smote, 將患病資料和未患病資料轉為約1:4的比率(原先約1:10)

# No Yes 292422 27373 After somte: No Yes 292422 82119

資料建模: 隨機森林

## 混淆矩陣:

```
Confusion Matrix:
val_pred
0 1
0 86994 732
1 10336 14299
```

## Result:

Accuracy:0.9 Precision:0.95 Recall:0.58 F1 Score:0.72

在是否患有心臟病的分析中, Recall應比Precision重要

相比於原先患病與未患病的比率(1:10), 雖然準確率差不多, 但Recall有顯著提高

## 原資料的:

```
Confusion Matrix:
val_pred
0 1
0 87593 133
1 7995 216
Accuracy:0.92
Precision:0.62
Recall:0.03
F1 Score:0.05
```

書瑋提供 - 變數間的相關性(使用R Cor()):

 $\frac{https://docs.google.com/spreadsheets/d/1IM2-4hOuFyP3FJt-YIv7QdDRmdFKmODZmsDmDpPo974/edit\#gid=0}{pPo974/edit\#gid=0}$ 

# 今晚討論紀錄:

- 1. 正晏: 會嘗試xgboost(下週四上課給); 視覺化先做dataset。
- 2. 元亨:會嘗試隨機森林(這週四上課給)。
- 昇豐:我會做特徵工程(PCA、ROC、AUC)、Hypothesis Test(chi-squre 完成的話, pass 給宗佑。)
- 4. 書瑋:特徵工程(PCA)【cor計算欄位相關、ROC、AUC】。

cor 計算欄位相關: 最後採用7個欄位也能得到0.9的準確率。

書瑋提供 - 變數間的相關性(使用R Cor()):

https://drive.google.com/drive/folders/1NKB5WjAGIUhrjHC9ABC6dFSyDZwdGpSl?usp=share\_linkhttps://docs.google.com/spreadsheets/d/1IM2-4hOuFyP3FJt-YIv7QdDRmdFKmODZmsDmDpPo974/edit#qid=0

5. 宗佑: HW2(null model、以及其他的confusion matrix的計算結果precision recall)

5/15 21:30~待討論

1. 決策數的層數加多。正晏可以看每一層用那些屬性。

>>昇:的確要調整rpart.control, 但不能只定義maxdepth, 就能生成決策樹. 且會預測YES了。

2. 書瑋建議資料平均. 讓YES、NO的資料一樣。

>> 昇:我用下列方式處理資料不平均

library('performanceEstimation') #instead of library('smotefamily')
smote\_f\_in\_csv <- smote(HeartDisease ~ ., data =f\_in\_csv[1:100000,])
for(i in colnames(smote\_f\_in\_csv))
{
 na nums <- 0</pre>

```
na_nums <- sum(is.na(smote_f_in_csv[[i]]))

if (na_nums > 0)
{
    print(i)
    print(na_nums)
}

smote後,會有NA
> nrow(smote_f_in_csv)
[1] 62937
> nrow(smote_f_in_csv[!is.na(smote_f_in_csv$HeartDisease),])
[1] 44955
> nrow(smote_f_in_csv[is.na(smote_f_in_csv$HeartDisease),])
[1] 17982
```

3. 正晏建議copy YES的資料, 讓它跟NO的依樣多。

>> 昇:沒有嘗試

4. PCA方法,或者暴力破解,挑出能夠預測YES的屬性集合。

>> 昇:沒有嘗試

昇: 參考鄉民: https://www.kaggle.com/code/karenhu8/hux-da5030-project

參考資料欄位說明 <a href="https://www.kaggle.com/code/andls555/heart-disease-prediction">https://www.kaggle.com/code/andls555/heart-disease-prediction</a>

1. 有18078列重複

```
summary(duplicate)
Mode FALSE T
                        ŤRUE
                      18078
logical
           301717
 head(f_in_csv[duplicate>0,])

HeartDisease BMI Smoking AlcoholDrinking Stroke PhysicalHealth
                         23.49
                                                           No
                     No
                                      No
                         30.13
                     No
                                       No
                                                           No
                                                                                        00000
                         28.89
291748
                     No
                                       No
                                                           No
                                                                    No
                                     Yes
171901
                     No
                                                           No
                                                                    No
255300
237263
                         24.03
                                       No
                                                           No
                                                                    No
        No 24.41 No
MentalHealth DiffWalking
                                                           No
                                                                    No
                                           Sex AgeCategory
male 50-54
Male 50-54
                                                                 Race Diabetic
112226
138352
291748
                                    No Female
                                                                White
                                    No
                                          Male
                                                                White
                                                                               No
                                                        55-59
35-39
                                          Male
                                    No
                                                                White
                                                                               No
171901
255300
                                          Male
                                                                White
                                    No
                                                                               No
                                                        60-64 White
                                    No Female
                                                                               No
237263
                                                        18-24 White
                                    No
                                          Male
                                                                               No
        PhysicalActivity GenHealth SleepTime Asthma KidneyDisease SkinCancer
                         Yes Excellent
                                                     778788
                                                            No
                                                                              No
                                                                                            No
                                                                              No
                         Yes Excellent
                                                                                            No
291748
                         Yes Very good
                                                            No
                                                                              No
                                                                                            No
71901
                                                            No
                         Yes
                                    Good
                                                                              No
                                                                                            No
 55300
                         Yes Excellent
                                                            No
                                                                              No
                                                                                            No
                         Yes Very good
                                                            No
                                                                              No
                                                                                            No
```

```
> nrow(f_in_csv)
[1] 319795
> f_in_csv <- distinct(f_in_csv)
> nrow(f_in_csv)
[1] 301717
```

## 2.1. 資料轉型

> str(f\_in\_csv)

'data.frame': 301717 obs. of 18 variables:

\$ HeartDisease : chr "No" "No" "No" "No" ... <--- target column

\_\_\_\_\_

**\$ BMI : num** 16.6 20.3 26.6 24.2 23.7 ...

\$ Smoking : chr "Yes" "No" "Yes" "No" ... <---- 轉成1,0

\$ AlcoholDrinking: chr "No" "No" "No" "No" ...

```
$ Stroke : chr "No" "Yes" "No" "No" ...
```

- **\$ PhysicalHealth : num** 3 0 20 0 28 6 15 5 0 0 ...
- **\$ MentalHealth : num** 30 0 30 0 0 0 0 0 0 0 ...
- \$ DiffWalking : chr "No" "No" "No" "No" ...
- \$ Sex : chr "Female" "Female" "Male" "Female" ...
- \$ AgeCategory : chr "55-59" "80 or older" "65-69" "75-79" ... <-- 這個要轉成num
- \$ Race : chr "White" "White" "White" ... ←-dummy
- \$ Diabetic: chr "Yes" "No" "Yes" "No" ...
- \$ PhysicalActivity: chr "Yes" "Yes" "Yes" "No" ...
- \$ GenHealth: chr "Very good" "Very good" "Fair" "Good" ...
- **\$ SleepTime : num** 5 7 8 6 8 12 4 9 5 10 ...
- \$ Asthma: chr "Yes" "No" "Yes" "No" ...
- \$ KidneyDisease : chr "No" "No" "No" "No" ...
- \$ SkinCancer: chr "Yes" "No" "No" "Yes" ...

上面紅字欄位資料含有多種類,因此用dummy把之展開

```
head(dummy_cols(f_in_csv, select_columns = c('Race', 'Diabetic', HeartDisease BMI Smoking AlcoholDrinking Stroke PhysicalHealth
No 16.60 Yes No No 3
No 20.34 No No Yes 0
                                                                                                             'GenHealth'$
                                                                                                            MentalHealth
                 No 16.60
No 20.34
No 26.58
No 24.21
No 23.71
                                                                                                                             30
0
30
0
0
                                                                   No
No
No
                                                                             Yes
                                       Yes
No
                                                                               No
No
                                                                                                        20
                                                                   Nο
                                                                               No
No
                                                                                                        28
                                         Nο
                                                                   Nο
                Yes 28.87
ng Sex
                                       Yes
                                                                   Nο
emale 8
No Female 77
Yes Female 42
Yes Female 77
SleepTime Asthma KidneyDisease
5 Yes No
7 No No
8 Yes
6 No
8 No
12 No
ce_Asian D
                                AgeCategory
57
                                                                            PhysicalActivity GenHealth
Yes Very good
Yes Very good
Yes Fair
 DiffWalking
                                                    Race Diabetic
White Yes
                                                    White
                                                                        N \circ
                                                 White
White
White
Black
Se SkinCancer Ra
Yes
No
No
                                                                       Yes
                                                    White
                                                                        No
No
                                                                                                    Νo
                                                                                                                 Good
                                                                                                   Yes
                                                                                                                 good
Fair
                                                                                                         Very
                                                                     No Pair
No Pair
Race_American Indian/Alaskan Native
0
0
0
0
0
0
                                                                Yes
                                                                 No
No
                   0000
 Diabetic_No, borderline diabetes Diabetic_Yes Diabetic_Yes (during pregnancy)
0 1 0
                                                                                                                               00000
                                                    000
                                                    0
 GenHealth_Excellent GenHealth_Fair
                                                          GenHealth_Good GenHealth_Poor
                                                        ŏ
1
                                                                                0
                               0
                               0
 GenHealth_Very good
                               0
                               Ô
```

```
HeartDisease
               16.60
20.34
26.58
            No
No
            Nο
Yes 28.87 1
DiffWalking Sex AgeCategory
0 0 57
0 0 80
0 1 67
0 0 77
1 0 42
           Yes
                                PhysicalActivity SleepTime Asthma KidneyDisease
1 5 1 0
1 7 0 0
                                                                    0
1
0
0
SkinCancer Race_American Indian/Alaskan Native Race_Asian Race_Black
Race_Hispanic Race_Other Race_White Diabetic_No
              0
0
0
0 0 U 1
Diabetic_No, borderline diabetes Diabetic_Yes Diabetic_Yes (during pregnancy)
0 1
                                   0 0
GenHealth Excellent GenHealth Fair GenHealth Good GenHealth Poor
GenHealth_Very good
ncol(f_in_csv_dummy)
1] 30
ncol(f_in_csv)
] 18
```

## 3. unblanced data

#> table(f\_in\_csv\$HeartDisease)

#

# No Yes

#274456 27261

3.1.

切3個fold

confusion matrix 依序是train, test, valid

 train\_correct\_percent太低的原因是, smote後的train\_set有NA(約1萬5 千筆), 應排除而未排除導致。

```
training_ls <- c(training_ls,
```

format(round(CP\_train\_correct\_num/**nrow(df\_train\_set)**, 2), nsmall = 2))

```
The 1-Fold: each fold has 100572 rows df_test_set is from 1 to 100572
 df_validate_set is from 100573 to 201144
df_train_set isn't within 1 to 100572 and 100573 to 201144 , balanced num is 63133
 No Yes
36076 9019
[1] "-----
             pred
 truth No Yes
No 34850 1226
Yes 6885 2134
 pred
truth No
No 88105
Yes 7022
                                Yes
3306
2139
pred
pred
truth No Yes
No 88193 3298
Yes 6993 2088
fold1's train_correct_percent is 0.59
fold1's test_correct_percent is 0.90
fold1's validate_correct_percent is 0.90
The 2-Fold: each fold has 100572 rows
df_test_set is from 100573 to 201144
df_validate_set is from 201145 to 301716
df_train_set isn't within 100573 to 201144 and 201145 to 301716 , balanced num is 64127
 No Yes
36644 9161
[1] "----
             pred
 truth No
No 34897
Yes 6332
                                Yes
1747
2829
  pred
truth No
No 86881
                                Yes
4610
2668
      Yes 6413
 res 0415 2000
pred
truth No Yes
No 87107 4446
Yes 6373 2646
fold2's train_correct_percent is 0.59
fold2's test_correct_percent is 0.89
fold2's validate_correct_percent is 0.89
```

```
The 3-Fold: each fold has 100572 rows

df_test_set is from 201145 to 301716

df_validate_set is from 301717 and backward to 100571

df_train_set isn't within 201145 to 301716 and 301717 and backward to 100571 , balanced num is 63567

No Yes
36324 9081

[1] "------

pred

truth No Yes
No 34975 1349
Yes 6708 2373
pred

truth No Ves
No 87993 3560
Yes 6703 2316
pred

truth No Yes
No 87784 3627
Yes 6756 2405

fold3's train_correct_percent is 0.59

fold3's test_correct_percent is 0.90

fold3's validate_correct_percent is 0.90

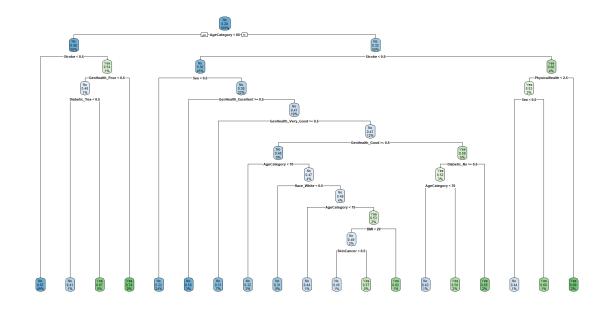
> ""

Page 100571

The 3-Fold is 100571

The
```

# 第三個fold的train的決策樹



# 5/11

# 2.5/15晚上, A組能討論的時間。

## 5/15 21:30~

- 1. 決策數的層數加多。正晏可以看每一層用那些屬性。
- 2. 書瑋建議資料平均, 讓YES、NO的資料一樣。
- 3. 正晏建議copy YES的資料, 讓它跟NO的依樣多。
- 4. PCA方法, 或者暴力破解, 挑出能夠預測YES的屬性集合。

下週四5/18, 能夠讓B組的接手做視覺。

## 3. 了解資料

> nrow(f\_in\_csv)

[1] 319795

> sum(ifelse(f\_in\_csv\$HeartDisease == "Yes", 1, 0))

[1] 27373

> sum(ifelse(f\_in\_csv\$HeartDisease == "No", 1, 0))

[1] 292422

```
3 # [1] 18 cols
 4 # [1] "HeartDisease"
                        "BMT"
                                         "Smoking"
                                                         "AlcoholDrinking"
   # [5] "Stroke"
                                                         "DiffWalking"
                        "PhysicalHealth"
                                         "MentalHealth"
                                         "Race"
"SleepTime"
                         "AgeCategory"
   # [9] "Sex"
                                                         "Diabetic"
   #[13] "PhysicalActivity" "GenHealth"
                                                         "Asthma"
 8 #[17] "KidneyDisease" "SkinCancer"
   # [1-1] no na value
   # [2] head(csv)
   # HeartDisease
                  BMI Smoking AlcoholDrinking Stroke PhysicalHealth MentalHealth
         No 16.60 Yes No No 3 30
No 20.34 No No Yes 0 0
   #1
14 #2
   #3
             No 26.58
                         Yes
                                       No No
                                                          20
                                                                      30
           No 24.21 No
No 23.71 No
Yes 28.87 Yes
                                       No
No
   #4
                                              No
                                                           0
                                                                      0
16
   #5
                                              No
                                                          28
                                                                       0
                                      No
                                             No
   # DiffWalking Sex AgeCategory Race Diabetic PhysicalActivity GenHealth
19
   #1 No Female 55-59 White Yes Yes Very good #2 No Female 80 or older White No Yes Very good
   #3
             No Male 65-69 White
                                        Yes
                                                       Yes Fair
   #4 No Female 75-79 White No
#5 Yes Female 40-44 White No
#6 Yes Female 75-79 Black No
                                                        No
                                                                Good
                                                       Yes Very good
24
                                                        No Fair
   # SleepTime Asthma KidneyDisease SkinCancer
   #1 5 Yes No
#2 7 No No
                                     Yes
                                    No
   #3 8 Yes No
#4 6 No No
29
                                       No
                                      Yes
           6 NO
8 NO
12 NO
31 #5
32 #6
                             No
                                      No
                             No
                                      No
   # [3] summary
                     BMI Smoking
35 #HeartDisease
                                                      AlcoholDrinking
36 #Length:319795 Min. :12.02 Length:319795 Length:319795
37 #Class: character 1st Qu.:24.03 Class: character Class: character
38 #Mode :character Median :27.34 Mode :character Mode :character
39
                      Mean :28.33
40
   #
                      3rd Qu.:31.42
41
   #
                      Max. :94.85
      Stroke
                     PhysicalHealth MentalHealth
42 #
                                                     DiffWalking
43 #Length:319795 Min. : 0.000 Min. : 0.000 Length:319795
44 #Class: character 1st Qu.: 0.000 1st Qu.: 0.000 Class: character
   #Mode :character Median : 0.000 Median : 0.000 Mode :character
45
                     Mean : 3.372 Mean : 3.898
46
                      3rd Qu.: 2.000 3rd Qu.: 3.000
Max. :30.000 Max. :30.000
47
48
   #
   # Sex
49 # Sex AgeCategory Race Diabetic
50 #Length:319795 Length:319795 Length:319795
                      AgeCategory
51 #Class:character Class:character Class:character Class:character
   #Mode :character Mode :character Mode :character
53
54
56
   #PhysicalActivity
                      GenHealth
                                         SleepTime
                                                          Asthma
                     Length: 319795
                                       Min. : 1.000 Length: 319795
   #Length: 319795
   #Class : character Class : character 1st Qu.: 6.000 Class : character
59
   #Mode :character Mode :character
                                        Median: 7.000 Mode: character
                                        Mean : 7.097
60
                                        3rd Qu.: 8.000
61
   #
62
                                        Max. :24.000
63
   #KidneyDisease SkinCancer
#Length:319795 Length:319795
    #KidneyDisease
                      SkinCancer
64
   #Class :character Class :character
65
66 #Mode :character Mode :character
```

```
69 # [4] no col if its data is numeric
 70 #[1] "col_name: HeartDisease"
 71 #[1] "No" "Yes"
72 #[1] "col_name: Smoking"
73 #[1] "Yes" "No"
 74 #[1] "col_name: AlcoholDrinking"
 75 #[1] "No" "Yes"
76 #[1] "col_name: Stroke"
 77  #[1] "No" "Yes"
78  #[1] "<mark>col_name</mark>: DiffWalking"
 79 #[1] "No" "Yes"
 80 #[1] "col_name: Sex"
 81 #[1] "Female" "Male"
86 #[1] "col_name : Race"
87 #[1] "White"
                                             "Black"
88 #[3] "Asian"
                                             "American Indian/Alaskan Native"
 89 #[5] "Other"
                                             "Hispanic"
 90 #[1] "col name: Diabetic"
 91 #[1] "Yes"
92 #[3] "No,
                                     "No"
     #[3] "No, borderline diabetes" "Yes (during pregnancy)"
 93 #[1] "col_name: PhysicalActivity"
 94 #[1] "Yes" "No"
 95 #[1] "col_name: GenHealth"
96 #[1] "Very good" "Fair" "Good" "Poor" "Excellent"
97 #[1] "col_name: SleepTime"
98 # [1] 5 7 8 6 12 4 9 10 15 3 2 1 16 18 14 20 11 13 17 24 19 21 22 23
99 #[1] "col_name: Asthma"
101 #[1] "col_name:
102 #[1] "No" "Yes"
103 #[1] "col name: SkinCancer"
104 #[1] "Yes" "No"
```

based on hw3's rpart and K-fold is 5:

```
1 rpart result
2 The 1-Fold: each fold has 63959 rows
3 df_test_set is from 1 to 63959
4 df_validate_set is from 63960 to 127918
5 df_train_set isn't within 1 to 63959 and 63960 to 127918
                                                                                                                                                                                                                                                                                                                                                                                            22 The 2-Fold: each fold has 63959 rows
23 df_test_set is from 63960 to 127918
                                                                                                                                                                                                                                                                                                                                                                                                             df_validate_set is from 127919 to 191877
df_train_set isn't within 63960 to 127918 and 127919 to 191877
| pred | p
                                                                                                                                                                                                                                                                                                                                                                                                               truth No
No 175363
Yes 16514
pred
truth No
No 58602
Yes 5357
pred
truth No
             6 pred
7 truth
                                                                                 No
                              ruth No
No 175133
Yes 16744
     10 pred
11 truth No
12 No 58687
13 Yes 5272
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Yes
                                                                          No Yes
     13 Yes 52/2 0
14 pred
15 truth No Yes
16 No 58602 0
17 Yes 5357 0
18 foldl's CP_train_correct_percent is 0.91
19 foldl's CP_test_correct_percent is 0.92
20 foldl's CP_validate_correct_percent is 0.92
                                                                                                                                                                                                                                                                                                                                                                                                                truth No Yes
No 58457 0
Yes 5502 0
fold2's CP_train_correct_percent is 0.91
fold2's CP_test_correct_percent is 0.92
fold2's CP_validate_correct_percent is 0.91
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             Yes
42 The 3-Fold: each fold has 63959 rows
43 df_test_set is from 127919 to 191877
44 df_validate_set is from 191878 to 255836
45 df_train_set isn't within 127919 to 191877 and 191878 to
46 pred
47 truth No Yes
                                                                                                                                                                                                                                                                                                                                                                                                    62 The 4-Fold: each fold has 63959 rows
63 df_test_set is from 191878 to 255836
64 df_validate_set is from 255837 to 319795
65 df_train_set_isn't within 191878 to 255836 and 255837 to 319795
                                                                                                                                                                                                                                                                                                                                                                                                                        pred
truth No
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   Yes
         47 truth No
48 No 175607
49 Yes 16270
                                                                                                                                                                                                                                                                                                                                                                                                                                ruth No
No 175746
Yes 16131
                                                 pred
                                                                                                                                                                                                                                                                                                                                                                                                                                                 pred
      51 truth No
52 No 58457
53 Yes 5502
                                                                                                                                                                                                                                                                                                                                                                                                                       truth No
No 58358
Yes 5601
                                                                                                              0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    0
     53 Yes 5502 0

1 pred
55 truth No Yes
56 No 58358 0
57 Yes 5601 0
58 fold3's CP_train_correct_percent is 0.92
59 fold3's CP_test_correct_percent is 0.91
60 fold3's CP_validate_correct_percent is 0.91
                                                                                                                                                                                                                                                                                                                                                                                                                       res 5601 0
| pred

truth No Yes
No 58318 0
Yes 5641 0
fold4's CP_train_correct_percent is 0.92
fold4's CP_test_correct_percent is 0.91
fold4's CP_validate_correct_percent is 0.91
```

```
82 The 5-Fold: each fold has 63959 rows
83 df test set is from 255837 to 319795
84 df_validate_set is from 1 to 63959
85 df train set isn't within 255837 to 319795 and 1 to 63959
86
        pred
87
   truth
             No
                    Yes
     No 175417
                      0
89
     Yes 16460
90
        pred
91
   truth
          No
                 Yes
92
     No 58318
                    0
93
     Yes 5641
94
         pred
95
   truth
             No
                  Yes
96
     No 58687
                    0
97
     Yes 5272
                    0
98 fold5's CP_train_correct_percent is 0.91
99 fold5's CP_test_correct_percent is 0.91
100 fold5's CP validate correct percent is 0.92
```

### 0. 選組長。

5~6人

人數	人數	人數	人數	人數
2	1	1	1	optional+1
optional+1	optional+1			
		正晏		
CARTER	書瑋	AUSTIN		
BUSKY				
JUDE				
*正晏				

2.2. data(input): a. 資料前處理:有無發現資料清洗的難處? 2.3. model: a. 選哪個模型進行ML?例如決策數、 XGBoost。 b. 選用哪個特徵工程來優化模型? c. null model定義與建立。	2.4. evaluation(ouput): a. 用哪個方法來評估模型好壞? 例如Hypothesis Test(包含Confusion matrix、 precesion and recall)、R-squre	2.5. present: a. 從第2~4階段選擇資料視覺作用之處: 例如 - 清洗前、後的資料樣貌。 - 最優模型的評估結果。 - 以及特徵工程過程上的評估結果。 可能得遵照老節的建議,一併做 on-line visualization。	2.6. deploy:除了製作還原專案的步驟, 在報告當下demo。	統整ReadMe.md
--	--	---	-------------------------------------	-------------

#### 共同做到:

- b. 用ReadMe.md做課堂報告即可。因此不熟者要練習。 >可以作圖放在ReadMe, 屆時瀏覽器打開圖片講解也可。
- c. 專案艱辛之處。
- d. 專案引用的套件與外部資料。
- 3. 會按git flow預設各分支的定義來做程式合作,因此不熟者要練習。待老師
- 公布期末repo的目錄結構後,再來討論各分支能做什麼事、不能做什麼事。

1	HeartDise	BMI	Smoking	AlcoholDri	Stroke	PhysicalHe I	MentalHea	DiffWalkin	Sex	AgeCatego	Race	Diabetic	PhysicalAc	GenHealth	SleepTime	Asthma	KidneyD	is∈ SkinC
2	No	16.6	Yes	No	No	3	30	No	Female	55-59	White	Yes	Yes	Very good	5	Yes	No	Yes
3	No	20.34	No	No	Yes	0	0	No	Female	80 or olde	White	No	Yes	Very good	7	No	No	No
4	No	26.58	Yes	No	No	20	30	No	Male	65-69	White	Yes	Yes	Fair	8	Yes	No	No
5	No	24.21	No	No	No	0	0	No	Female	75-79	White	No	No	Good	6	No	No	Yes
6	No	23.71	No	No	No	28	0	Yes	Female	40-44	White	No	Yes	Very good	8	No	No	No
7	Yes	28.87	Yes	No	No	6	0	Yes	Female	75-79	Black	No	No	Fair	12	No	No	No
8	No	21.63	No	No	No	15	0	No	Female	70-74	White	No	Yes	Fair	4	Yes	No	Yes
9	No	31.64	Yes	No	No	5	0	Yes	Female	80 or olde	White	Yes	No	Good	9	Yes	No	No
10	No	26.45	No	No	No	0	0	No	Female	80 or olde	White	No, borde	No	Fair	5	No	Yes	No
11	No	40.69	No	No	No	0	0	Yes	Male	65-69	White	No	Yes	Good	10	No	No	No
12	Yes	34.3	Yes	No	No	30	0	Yes	Male	60-64	White	Yes	No	Poor	15	Yes	No	No
13	No	28.71	Yes	No	No	0	0	No	Female	55-59	White	No	Yes	Very good	5	No	No	No
14	No	28.37	Yes	No	No	0	0	Yes	Male	75-79	White	Yes	Yes	Very good	8	No	No	No
15	No	28.15	No	No	No	7	0	Yes	Female	80 or olde	White	No	No	Good	7	No	No	No
16	No	29.29	Yes	No	No	0	30	Yes	Female	60-64	White	No	No	Good	5	No	No	No
17	No	29.18	No	No	No	1	0	No	Female	50-54	White	No	Yes	Very good	6	No	No	No
18	No	26.26	No	No	No	5	2	No	Female	70-74	White	No	No	Very good	10	No	No	No
19	No	22.59	Yes	No	No	0	30	Yes	Male	70-74	White	No, border	Yes	Good	8	No	No	No

## 2. 下週4/27下課後可討論幾點:

- 0. 選組長。
- 1. 是否對主題有興趣?若否, 可直接去問其他隊, 沒問題的。
- 2. 從practice\_R教科書的資料科學流程討論:(如有未健全處, 再補充可)
  - 2.1. goal:要解決什麼問題?我們就可定義期末報告的主題集合。
  - 2.2. data(input):
    - a. 資料前處理:有無發現資料清洗的難處?
  - 2.3. model:
    - a. 選哪個模型進行ML?例如決策數、XGBoost。
    - b. 選用哪個特徵工程來優化模型?

c. null model定義與建立。

# 2.4. evaluation(ouput):

## 2.5. present:

- a. 從第2~4階段選擇資料視覺作用之處:
  - 例如
  - 清洗前、後的資料樣貌。
  - 最優模型的評估結果。
  - 以及特徵工程過程上的評估結果。

可能得遵照老師的建議. 一併做on-line visualization。

- b. 用ReadMe.md做課堂報告即可。因此不熟者要練習。
- c. 專案艱辛之處。
- d. 專案引用的套件與外部資料。
- 2.6. deploy:除了製作還原專案的步驟, 在報告當下demo。

```
15min+5min Q&A
finalproject_group1 >
all report putted in github is ok; no more ppt to deliver
- goal
- input
  source \ preprocess
- modeling
  method \ null model for comparison \
- output
 performance: precision > recall > R-squre ; improvement is significant
- demo
 on-line visualization > reproduce your result by other team
 challenges in project
- references
  indicate in your presentation if you use code for others.
  package used
  related publications
```